

第一次挑战：作业感受

我是怎么完成这次挑战的

我先在 WSL 的 Ubuntu 22.04 中准备环境，分别安装 SGLang 0.5.14 和 Ray 2.56.0，用 Qwen/Qwen3-0.6B 启动本地服务。服务能返回 /v1/models 的模型列表，也完成了一次对话请求。随后，我从 Mooncake FAST25 的 trace 中取了 12 条记录，写脚本按指数分布安排请求间隔，经 HTTP 发送到 SGLang，并把 token 数、状态码和延迟保存为 CSV。12 条请求都返回了 200。过程中我用 AI 帮忙拆解安装报错和命令，也用它核对脚本思路；每一步是否成功，还是靠终端输出和实际请求来确认。

最费时间的地方

卡住我的主要是环境。起初在 E 盘挂载目录创建虚拟环境时，ensurepip 失败；后来又误进了 docker-desktop 的 WSL 环境，连 curl 和 sudo 都找不到。切回 Ubuntu 后，服务启动还牵涉 CUDA 工具链和 C 盘空间，我只好逐项检查并把相关环境迁到 E 盘。另一个容易忽略的问题是 trace 中的输入长度动辄几万 token，直接照搬并不适合这台机器。脚本把输入长度按 1/128 缩放，再限制在 32 到 320 token，输出最多 48 token。这样做能验证请求链路，但不能把表中的延迟解释成原始 Mooncake trace 的性能结果。

对以后做研究的提醒

这次从论文概念走到可运行的服务，我才发现“跑通”和“比较性能”之间隔着不少工作。以后遇到从零开始的课题，我会先弄清问题和评价指标，再对照论文与文档搭建最小实验；记录版本、参数和失败过程，保留能复查的输入与结果。尤其是改动 workload 时，要把缩放规则和原因写清楚，否则数字看起来很完整，结论却可能站不住。