

SGLang 在线推理：一次请求如何完成

从 OpenAI-compatible HTTP 请求到模型回复；缓存命中时只计算未覆盖的输入

